УДК 004.8

Ресурсная эффективность локальных языковых моделей в аграрных задачах: сравнение конфигураций 9B и 27B и использование расчётных инструментов

Антоний Сарычев, Денис Шестернин

РГАУ-МСХА имени К.А. Тимирязева, Москва, Россия

Аннотация. Локальная модель Qwen 9B верно ответила на 141/289 вопросов открытой выборки аграрного набора MERA против 150/289 у 27B и в отдельном замере работала быстрее, занимая меньше памяти. Выполнение расчётных функций дало обеим моделям 16/16 численных ответов, но ошибки уточнения данных у 9B сохранились.

Ключевые слова: языковые модели; локальный вывод; сельское хозяйство; ресурсная эффективность; расчётные инструменты; воспроизводимость.

Введение

Локальный аграрный ассистент получает запросы двух видов: вопросы на предметные знания и расчёты по явно заданной формуле. Во втором случае связный ответ не гарантирует верного числа, а правильно названный инструмент — того, что расчёт действительно выполнен. При ограниченной памяти персонального компьютера модель приходится выбирать с учётом качества всей конфигурации, задержки ответа, занятой памяти и наблюдавшихся отказов.

Цель работы — описать практический компромисс между качеством и ресурсами у двух локальных конфигураций семейства Qwen с 9 и 27 млрд параметров и оценить, что даёт реальное выполнение расчётных функций. Рассматриваются три вопроса: (1) какую часть качества модели 27B сохраняет модель 9B на аграрном наборе и как различаются задержка и память; (2) чем самостоятельный расчёт модели отличается от передачи аргументов проверяемой функции с её фактическим выполнением; (3) дополнительно — что показывают имеющиеся эксперименты с обращением к облачным моделям, включая отрицательные результаты. Конфигурации различаются поколением, размером, квантованием и размещением в памяти, поэтому причинный эффект числа параметров не выделяется. Модель 9B рассматривается как основной практический вариант, 27B — как вариант для сравнения с более высоким наблюдаемым качеством.

Связанные работы

FrugalGPT, AutoMix, Hybrid LLM, RouteLLM и единый подход к маршрутизации и каскадам формализуют выбор модели и передачу запроса более сильной модели [1–5]. RouterBench отделяет анализ сохранённых ответов от поведения работающего маршрутизатора [6]. Исследования семантической энтропии и обзор методов отказа от ответа показывают, что надёжность требует явно заданного критерия неопределённости или отказа [7, 8]; синтаксически корректный JSON или поле самооценки уверенности таким критерием не являются.

PLLaMa, AgriGPT и AgroLLM исследуют адаптацию языковых моделей к аграрной области [9–11], а AgriAgent и AgroTools — планирование и использование инструментов в сельском хозяйстве [12, 13]; сочетание аграрной тематики и инструментов уже сложилось как направление исследований. τ-bench оценивает достигнутый результат взаимодействия агента с пользователем, ToolACE — данные и проверку вызовов функций [14, 15]. Вклад настоящей работы уже: сравнение ресурсов локальных конфигураций и разграничение указанного и фактически выполненного расчёта.

BitNet и технический отчёт Gemma 4 описывают разные подходы к эффективным архитектурам [16, 17], но не содержат измерений для используемых здесь файлов моделей. AgXQA представляет другой тип аграрных вопросов и использовался только в предварительных экспериментах [18]. Расчётные формулы взяты из руководства FAO-56 [19], платформа оценки MERA описана в [20].

Материалы и методы

Данные

Набор ruTXTAgroBench платформы MERA содержит 2 935 русскоязычных вопросов с выбором ответа по десяти аграрным дисциплинам; 293 задания входят в открытую выборку, используемую для разработки и оценки, эталонные ответы остальных заданий закрыты [20, T1]. Создатели набора сообщают, что вопросы составлены агрономами, отредактированы и перепроверены тремя экспертами; это описание авторов набора, а не наша независимая проверка каждого эталона или пригодности совета для конкретного хозяйства. Вопросы, эталонные ответы и полные журналы хранятся локально с ограничениями на распространение.

Начальная сбалансированная подборка из 60 заданий входит в открытую выборку и использовалась при выборе моделей. Для измерения ресурсов из той же выборки отдельно взяты 40 заданий — по четыре из каждой дисциплины, без отбора по правильности ответов (далее — подвыборка из 40 заданий); 20 из них входят и в начальную подборку, поэтому независимой проверкой подвыборка не является. Отдельный расчётный эксперимент включает 27 сконструированных русскоязычных заданий с повторяющимися семействами формул. Предыдущий контролируемый эксперимент на 150 синтетических и двуязычных заданиях используется только как дополнительный контекст. Точности этих блоков не объединяются; закрытая тестовая выборка MERA не использовалась.

Оценка качества

Строгая оценка точного совпадения (EM) требует равенства множеств латинских обозначений выбранных вариантов. F1 — гармоническое среднее точности и полноты множества, усреднённое по заданиям. Четыре исходных эталона смешивают кириллицу и латиницу и не разбираются по заявленному правилу; их не транслитерировали и не исправляли. Основной знаменатель равен 289, все 293 ответа сохранены, консервативный расчёт с нулём для этих четырёх строк приведён отдельно.

Опубликованная процедура оценки MERA использует нормализацию SQuAD, которая, в частности, может удалить латинскую «A» как английский артикль, поэтому её результаты расходятся со строгими EM и F1. Реализацию оцен-

ки на сервере MERA независимо проверить не удалось; поэтому воспроизводимая локально строгая метрика приводится отдельно, а официальный результат MERA не заявляется. Интервалы на многократно использованной открытой выборке носят описательный характер; допустимая граница потери качества для модели 9B заранее не задавалась.

Модели, оборудование и режимы запуска

Сравниваются две конфигурации: Qwen3.5-9B с квантованием Q8_0 (файл GGUF 8,873 GiB; далее — модель 9B) и Qwen3.8-27B с квантованием UD-Q4_K_M (15,334 GiB; далее — модель 27B); идентичность файлов подтверждена контрольными суммами SHA-256. Измерения выполнены на одном компьютере: процессор AMD Ryzen 7 8700F, видеокарта RTX 5060 Ti с 16 311 MiB памяти, 31,620 GiB оперативной памяти; Windows 11 Pro, драйвер NVIDIA 617.14, LM Studio 0.4.25+1 со средой выполнения llama.cpp CUDA12 версии 2.51.0; точная сборка движка для каждой модели не раскрывается.

Основной прогон на полной открытой выборке выполнялся через OpenAI-совместимый интерфейс с проверкой ответа по строгой JSON-схеме. Генерация шла при температуре 0, параметре top_p = 1 и фиксированном начальном значении генератора 42; контекст составлял 2 048 токенов, максимальная длина ответа — 512 токенов, режим рассуждений был отключён. Для модели 9B запрашивалось максимальное размещение на GPU, для 27B — 75 %; кэшировалось 32 контрольные точки, фактическое число слоёв на GPU не измерялось.

Подвыборка из 40 заданий выполнялась через собственный REST-интерфейс LM Studio (далее — профиль измерения ресурсов) с теми же входными текстами, контекстом, параметрами декодирования и лимитом длины, но без явного начального значения генератора и серверной проверки схемы. Кэширование контрольных точек было отключено, размещение на GPU — автоматическим, многотокенное предсказание — выключенным. Модели запускались поочерёдно блоками по схеме ABBA с отдельным синтетическим прогревом и явной выгрузкой; загрузка и прогрев в задержку запроса не входят.

Память измерялась периодическим опросом в трёх областях: общая занятая видеопамять устройства, общая занятая оперативная память системы и резидентная память (RSS) группы процессов LM Studio; приводятся максимальные наблюдавшиеся значения. Фоновые приложения и разделяемые страницы входят в эти величины, поэтому собственный объём памяти модели не установлен. Задержка — время полного HTTP-запроса на стороне клиента; время до первого токена (TTFT) на стороне клиента и сервера различается. Скорость коротких ответов буквами не характеризует длинную генерацию; энергопотребление не измерялось.

Результаты

Качество и ресурсы

Таблица 1. Качество моделей на полной открытой выборке MERA: 293 задания, 289 разбираемых эталонов; основной прогон, все запросы выполнены.

Конфигурация	Строгая EM	F1	Задержка p50 / p95, с
Qwen3.5-9B Q8_0	141/289; 48,79 %	0,6286	0,295 / 0,402
Qwen3.8-27B UD-Q4_K_M	150/289; 51,90 %	0,6468	1,374 / 1,753

Разность EM моделей 9B и 27B составляет −3,11 п. п. Обе модели верны в 113 заданиях, только 9B — в 28, только 27B — в 37, обе неверны в 111. Сохранённый бутстреп с расслоением по дисциплинам (10 000 повторов) даёт описательный 95-процентный интервал разности EM [−8,30; +2,42] п. п. и F1 [−0,06148; +0,02552]. Отношение 141/150 = 94 % — это отношение числа верных ответов двух конфигураций, а не точность: точность модели 9B равна 48,79 %, эквивалентность не установлена. Консервативный расчёт по всем 293 заданиям даёт 141/293 = 48,12 % и 150/293 = 51,19 %; истинных ответов четырёх спорных строк он не устанавливает.

Таблица 2. Качество и ресурсные показатели на подвыборке из 40 заданий (профиль измерения ресурсов): качество оценено ретроспективно по 39 эталонам, задержка и память — по 40 завершённым запросам каждой модели.

Показатель	Модель 9B	Модель 27B
Строгая EM	22/39; 56,41 %	24/39; 61,54 %
F1	0,7197	0,7801
Задержка p50 / p95, с	0,269 / 0,344	1,434 / 1,829
TTFT клиента, p50, с	0,122	0,691
Пик видеопамяти устройства, MiB	11 471	13 287
Пик оперативной памяти системы, GiB	20,858	28,470
Пик RSS процессов LM Studio, MiB	11 198,96	18 742,34
Завершено / нарушения формата JSON	40/40 / 2	40/40 / 0

На этой подвыборке медианная задержка модели 9B в 5,338 раза меньше, а модель 27B верно отвечает на два задания больше; ни одна конфигурация не превосходит другую по всем показателям.

Сверка 80 пар запросов двух профилей подтвердила побайтовое совпадение системных и пользовательских сообщений и записей об идентичности весов, однако выбранные варианты изменились в 1 из 40 заданий у модели 9B и в 2 из 40 у модели 27B. Ответы основного прогона на те же задания дали обеим моделям по 23/39 (F1 0,7282 и 0,7374). Поэтому качество на полной выборке и задержку на подвыборке нельзя представлять как одновременные измерения при одинаковых настройках; совместно описываются только показатели самой подвыборки.

Первый вариант профиля измерения ресурсов с кэшированием 32 контрольных точек привёл к остановкам модели 27B защитным ограничением по оперативной памяти; с отключённым кэшированием подвыборка завершена полностью, а отказы сохранены в журналах как операционные, а не как ошибки ответа. Одна успешная серия не подтверждает долговременную устойчивость.

Расчётный эксперимент и выполнение инструментов

Во всех режимах расчётного эксперимента модель получает тип задачи, вопрос, входные числа и единицы. Проверяются: сумма эффективных температур (GDD) без верхнего ограничения — max(0, (Tmin + Tmax)/2 − Тбаз), суммируемая по заданным дням; давление насыщения и дефицит давления пара (VPD), для одного наблюдения равный давлению насыщения, умноженному на (1 − RH/100), а в суточной версии рассчитываемый по экстремумам температуры и влажности; суточная эталонная эвапотранспирация ET0 по FAO-56 [19]; заданная в эксперименте разность max(0, целевое значение − сумма осадков). Разность осадков не является нормой полива, а ET0 — ни эвапотранспирацией культуры ETc, ни дозой орошения [19]. Недостающие измерения, скорость ветра, поток тепла в почву G и пороги культуры не подставляются ни из эталона, ни из типовых значений.

На первом этапе, без фактического выполнения функций, полная правильность моделей 9B и 27B составила 7/27 и 15/27, правильное число с единицами — 1/16 и 6/16, правильно указанный инструмент — 17/26 и 25/26 (без неподдерживаемого задания); расчётный модуль совпал с независимо построенными формульными эталонами в 27/27 случаях. Повторный расчёт по сохранённым ответам передавал коду исходные данные напрямую и поэтому не проверял передачу аргументов моделью; задержки двух моделей на этом этапе несравнимы из-за разных настроек кэширования.

Второй, заранее описанный этап завершил все 108 решений (27 заданий × 2 модели × 2 режима): 140 измеряемых вызовов моделей и два отдельных синтетических прогрева. Обе модели работали в профиле измерения ресурсов без кэширования контрольных точек. В режиме без инструментов модель делает один вызов. В режиме с выполнением инструментов модель выбирает разрешённую функцию и передаёт полный набор аргументов; программа сверяет их с исходными данными задания и единицами, выполняет формулу и возвращает результат модели для итогового ответа. Аргументы не дополняются ни из эталона, ни из скрытой категории, ни из ожидаемого инструмента. Это выполнение через JSON на уровне приложения при явно заданных типе задачи и формате обмена; встроенный механизм вызова функций и распознавание намерения в свободном тексте не проверялись.

Таблица 3. Расчётный эксперимент: 27 заданий в каждом режиме. Полная правильность — по исходной процедуре оценки значения, действия и инструмента; соответствие итогового JSON проверено отдельно. Задержка — медиана суммы времени HTTP-запросов к модели без диспетчеризации и журналирования.

Модель и режим	Верно	Число и единица	Выполнений	Медиана суммы, с
9B без инструментов	7/27	1/16	0	1,469
9B с инструментами	18/27	16/16	16	2,857
27B без инструментов	15/27	6/16	0	8,989
27B с инструментами	25/27	16/16	16	21,879

Все 32 численных вызова прошли проверку аргументов и дали правильные итоговые значения с единицами. Среди 11 нечисленных заданий модель 9B получила 6/11 без инструментов и 2/11 с инструментами, модель 27B — 9/11 в обоих

режимах. Следовательно, улучшение арифметики не означает надёжного уточнения недостающих данных и отказа от неподдерживаемой задачи: у модели 9B четыре таких случая ухудшились. Ошибок связи и усечений по лимиту длины ответа не наблюдалось. Отдельная проверка формата итогового JSON баллов в таблице 3 не меняет, поскольку ответы с нарушением типов уже неверны по исходной оценке; с требованием разрешённого идентификатора инструмента ей соответствуют 22/27 и 19/27 ответов модели 9B.

Лимит в 512 токенов задан на один вызов; успешный численный расчёт с инструментом обычно требует двух вызовов и получает вдвое больший суммарный лимит, а обратная связь от инструмента меняется вместе с числом вызовов. Приведена сумма задержек запросов к модели, а не полная задержка приложения.

Сохранены исходные допуски каждого задания (10^{-8} для двенадцати высокоточных эталонов; 0,001, 0,005 или 0,01 для четырёх опубликованных округлённых примеров); вспомогательная диагностика с допуском max(исходный допуск, 10^{-4}) строгих баллов не заменяет. Допуск относится к формуле, а не к агрономической безопасности: совпадение с формульным эталоном не подтверждает правильность полевого решения.

Дополнительные наблюдения: обращение к облачным моделям

Эти наблюдения не образуют единого рейтинга облачных моделей: они получены на разных выборках и в разных условиях, Codex CLI оценивался как готовый продукт со своей программной обвязкой, результаты Claude Code на заданиях получить не удалось, а модели, размещённые у провайдеров, не обязательно совпадают с локальными файлами.

Mercury 2.5 в режиме instant с лимитом 512 токенов на подборке из 60 заданий дала 31/59 строгих совпадений, включая четыре неуспешные или усечённые попытки. Повторный расчёт передачи запросов от модели 9B (37/59) к Mercury по сохранённым ответам не улучшил EM: лучший сохранённый ненулевой порог дал 35/59. Доли обращений к облаку здесь смоделированы, задержка и стоимость каскада не измерялись.

На девяти заданиях собственного предварительного набора размещённые в сервисе OpenRouter Qwen3.8-27B, Ling3.0-Flash-Sante и Dots3-Note-Preview дали 5/9, 4/9 и 4/9 по процедуре оценки этого набора. Codex CLI на подборке из 60 заданий MERA дал 36/59 при среднем уровне рассуждений и 46 нарушениях формата JSON; задержка этого продукта включает запуск процесса, а подписка имеет стоимость.

В предыдущем контролируемом эксперименте на 150 заданиях режим «инструменты и облако» получил 139/150, локальный каскад — 133/150 при 20 обращениях к облаку вместо 100, но не выполнил заданного критерия качества. В отдельной серии на 36 заданиях того же собственного набора правила дали 31/36, отдельный маршрутизатор запросов — 30/36 при росте внешних запросов с 23 до 56. Эти серии показывают, что передача запросов в облако может не окупаться, но не доказывают пользы облачной маршрутизации для основной задачи.

Обсуждение и ограничения

Открытая выборка многократно использовалась при настройке и выборе моделей; подвыборка из 40 заданий и сконструированный расчётный эксперимент не являются независимой внешней проверкой. Один компьютер, разные поколения и квантования моделей, разные интерфейсы и размещение в памяти, отключённые рассуждения и короткий лимит длины ответа ограничивают обобщение. Экспертное происхождение набора не гарантирует безошибочности эталонов и безопасности рекомендаций.

Заключение

В рассмотренных условиях модель 9B занимает меньше измеренной памяти и отвечает быстрее, а модель 27B показывает более высокое наблюдаемое качество (150/289 против 141/289 на полной открытой выборке). Это основание выбирать конфигурацию под явно заданный практический бюджет, а не вывод об универсальном превосходстве или эквивалентности. Расчётный режим следует оценивать по аргументам, выполнению и итоговому ответу, а не по названию инструмента: реальное выполнение подняло число правильных численных ответов с 1/16 и 6/16 до 16/16 у обеих моделей, но у модели 9B сохранились ошибки выбора инструмента и уточнения данных, а успешный расчёт требует дополнительного вызова модели. Облачные наблюдения носят дополнительный характер и выигрыша от передачи запросов не показали. Следующий шаг — проверка на независимом тестовом наборе и оценка новых открытых моделей при тех же ограничениях ресурсов.

Использование ИИ и вклад авторов

Генеративный ИИ существенно использовался в работе: агенты Codex — при разработке и выполнении экспериментального кода, организации доказательной базы, проверке источников, поддержке анализа и подготовке черновиков; Claude — при редактировании текста и проверке библиографии. Проверка, выполненная ИИ, не является человеческим рецензированием. Авторы несут ответственность за утверждения, библиографию, права и интерпретацию; описание вкладов и окончательное согласие обоих авторов с текстом ожидают подтверждения. Протоколы, контрольные суммы и журналы попыток, включая внутренние обозначения выборок и экспериментов, сохранены в репозитории проекта. Программный код распространяется по лицензии Apache-2.0; лицензия рукописи и права на данные определяются отдельно.

Список литературы

1. Chen L., Zaharia M., Zou J. FrugalGPT: How to Use Large Language Models While Reducing Cost and Improving Performance // arXiv preprint. 2023. arXiv:2305.05176.
2. Aggarwal P., Madaan A., Anand A. et al. AutoMix: Automatically Mixing Language Models // Advances in Neural Information Processing Systems 37 (NeurIPS 2024). 2024. P. 131000–131034. DOI: 10.52202/079017-4164.
3. Ding D., Mallick A., Wang C. et al. Hybrid LLM: Cost-Efficient and Quality-Aware Query Routing // International Conference on Learning Representations (ICLR 2024). 2024. arXiv:2404.14618.
4. Ong I., Almahairi A., Wu V. et al. RouteLLM: Learning to Route LLMs from Preference Data // International Conference on Learning Representations (ICLR 2025). 2025. Препринт: arXiv:2406.18665 (под названием «RouteLLM: Learning to Route LLMs with Preference Data»).

5. Dekoninck J., Baader M., Vechev M. A Unified Approach to Routing and Cascading for LLMs // Proceedings of the 42nd International Conference on Machine Learning (ICML 2025). PMLR. 2025. Vol. 267. P. 12987–13010.
6. Hu Q. J., Bieker J., Li X. et al. RouterBench: A Benchmark for Multi-LLM Routing System // arXiv preprint. 2024. arXiv:2403.12031.
7. Kossen J., Han J., Razzak M. et al. Semantic Entropy Probes: Robust and Cheap Hallucination Detection in LLMs // arXiv preprint. 2024. arXiv:2406.15927.
8. Wen B., Yao J., Feng S. et al. Know Your Limits: A Survey of Abstention in Large Language Models // Transactions of the Association for Computational Linguistics. 2025. Vol. 13. P. 529–556. DOI: 10.1162/tacl_a_00754.
9. Yang X., Gao J., Xue W. et al. PLLaMa: An Open-source Large Language Model for Plant Science // arXiv preprint. 2024. arXiv:2401.01600.
10. Yang B., Zhang Y., Feng L. et al. AgriGPT: a Large Language Model Ecosystem for Agriculture // arXiv preprint. 2025. arXiv:2508.08632.
11. Samuel D. J., Skarga-Bandurova I., Sikolia D. et al. AgroLLM: Connecting Farmers and Agricultural Practices through Large Language Models for Enhanced Knowledge Transfer and Practical Application // arXiv preprint. 2025. arXiv:2503.04788.
12. Yang B., Zhang Y., Chen Y. et al. AgriAgent: Contract-Driven Planning and Capability-Aware Tool Orchestration in Real-World Agriculture // arXiv preprint. 2026. arXiv:2601.08308.
13. Ye Z., Wen Y., Fan X. et al. AgroTools: A Benchmark for Tool-Augmented Multimodal Agents in Agriculture // arXiv preprint. 2026. arXiv:2605.22366.
14. Yao S., Shinn N., Razavi P., Narasimhan K. τ-bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains // International Conference on Learning Representations (ICLR 2025). 2025. arXiv:2406.12045.
15. Liu W., Huang X., Zeng X. et al. ToolACE: Winning the Points of LLM Function Calling // International Conference on Learning Representations (ICLR 2025). 2025. arXiv:2409.00920.
16. Ma S., Wang H., Ma L. et al. The Era of 1-bit LLMs: All Large Language Models are in 1.58 Bits // arXiv preprint. 2024. arXiv:2402.17764.
17. Gemma Team. Gemma 4 Technical Report // arXiv preprint. 2026. arXiv:2607.02770.
18. Kpodo J., Kordjamshidi P., Nejadhashemi A. P. AgXQA: A benchmark for advanced Agricultural Extension question answering // Computers and Electronics in Agriculture. 2024. Vol. 225. Art. 109349. DOI: 10.1016/j.compag.2024.109349.
19. Allen R. G., Pereira L. S., Raes D., Smith M. Crop evapotranspiration: Guidelines for computing crop water requirements. FAO Irrigation and Drainage Paper 56. Rome: FAO, 1998. ISBN 92-5-104219-5.
20. Fenogenova A., Chervyakov A., Martynov N. et al. MERA: A Comprehensive LLM Evaluation in Russian // Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2024. P. 9920–9948. DOI: 10.18653/v1/2024.acl-long.534.

Технические источники

T1. ruTXTAgroBench: описание задачи MERA Industrial [Электронный ресурс] // MERA. URL: https://mera.a-ai.ru/ru/industrial/tasks/1 (дата обращения: 04.10.2026).

Сведения на английском языке

Title: Resource-Efficient Local Language Models for Agricultural Tasks: A 9B–27B Comparison with Deterministic Tools

Authors: Antoniy Sarychev, Denis Shesternin. Russian State Agrarian University — Moscow Timiryazev Agricultural Academy, Moscow, Russia

Abstract. A local Qwen 9B configuration answered 141/289 questions of the public MERA agricultural development set correctly versus 150/289 for 27B and, in a separate measurement, ran faster with less memory. Executing calculation functions gave both models 16/16 numeric answers, but 9B clarification errors remained.

Keywords: language models; local inference; agriculture; resource efficiency; calculation tools; reproducibility.

Рабочая редакция от 5 октября 2026 г. Русская и английская версии описывают одно исследование; согласие авторов, лицензия и УДК подлежат подтверждению.