Денису: суть исследования

Памятка к разговору с Анастасией Греченевой • 7 октября 2026
Страница 1: что сделали и что получилось

Главная мысль. Проверили, насколько небольшая языковая модель на обычном ПК уступает более крупной в аграрных вопросах и помогает ли ей подключение точных расчётных функций. Меньшая модель быстрее и экономнее по памяти; для чисел полезны формулы, но ошибки понимания задачи остаются.

1. Какая проблема и что за проект

Аграрному ИИ-ассистенту нужно и отвечать на вопросы, и считать. Большая модель требует больше ресурсов; связный ответ ещё не гарантирует правильного числа. Мы собрали программный стенд, который запускает модели, проверяет ответы, измеряет время и память и подключает расчётные функции.

Сравнивали: Qwen3.5-9B и Qwen3.8-27B. 9B и 27B означают примерно 9 и 27 млрд параметров. Обе работают локально. ПК: RTX 5060 Ti с 16 ГБ видеопамяти, около 32 ГБ оперативной памяти. Сравнение относится к этим конкретным конфигурациям.

2. На каких данных проверяли знания

ruTXTAgroBench платформы MERA: 2 935 русскоязычных вопросов с выбором ответа по 10 аграрным дисциплинам. По описанию создателей, вопросы подготовлены и проверены экспертами. Мы использовали **293 открытых задания**; закрытую тестовую часть не запускали.

На открытой выборке	Модель 9B	Модель 27B
Полностью верный выбор вариантов	141 из 289 48,79 %	150 из 289 51,90 %

Четыре эталона имели неоднозначные обозначения букв, поэтому основной расчёт сделан по 289. Большая модель дала на 9 верных ответов больше: разница **3,11 процентного пункта**. Проверка строгая: должны совпасть все выбранные варианты.

3. Отдельно измерили скорость и память

На **40 вопросах** в отдельном режиме типичное время запроса составило **0,269 с у 9B и 1,434 с у 27B**: 9B быстрее примерно в **5,3 раза**. Качество именно здесь: 22/39 и 24/39; один эталон спорный. Пик занятой оперативной памяти всей системы: 20,86 и 28,47 GiB. Это отдельный замер, его настройки отличались от полного прогона.

4. Проверили реальные расчётные функции

27 собственных заданий: 16 численных и 11 на уточнение данных / обработку ограничений. Примеры: сумма эффективных температур, дефицит давления пара, эталонная эвапотранспирация по FAO-56. Сравнили ответ модели самой и работу с функцией: модель передаёт данные, программа проверяет их и считает.

Численные задачи: 9B без функций решила **1/16**, 27B - **6/16**; с фактическим выполнением функций обе дали **16/16**. По всем 27 заданиям: 9B **7** → **18** верных, 27B **15** → **25**. Выполнены 32 реальных расчёта. У 9B ошибки уточнения данных сохранились; расчётный режим требует дополнительного обращения к модели.

Как рассказать на паре

Страница 2: готовая речь, вопросы преподавателю и ответы на уточнения

Речь примерно на минуту: достаточно сказать это

«Мы провели предварительное исследование локальных языковых моделей для аграрных задач. Сравнили две модели Qwen: на 9 и 27 миллиардов параметров. Взяли 293 открытых вопроса аграрного набора MERA; из 289 оцениваемых меньшая модель ответила правильно на 141, большая - на 150. В отдельном замере на 40 вопросах меньшая отвечала примерно в пять раз быстрее и занимала меньше памяти.

Ещё проверили расчёты по агрометеорологическим формулам. Когда модели считали сами, ошибок было много; с реальным выполнением программных функций обе решили все 16 численных задач. Но при нехватке данных ошибки остались.

Пока вывод такой: небольшая модель интересна по ресурсам, а точные расчёты лучше передавать проверяемым функциям. Хотели бы уточнить, достаточно ли такого эксперимента для статьи, корректна ли методика и какую дополнительную проверку вы бы посоветовали».

Если решите показать статью

«Результаты уже оформлены в **рабочий черновик, бета-версию**, на русском и английском. Это одна работа. Хотим обсудить с вами данные, методику и выводы, получить замечания и доработать текст».

Можно начать с результатов, а текст показать при обсуждении. Проведённые тесты называем проведёнными; независимую проверку - планируемой.

Что уточнить у Греченевой

• **Фокус:** подходит ли тема локальных моделей, их ресурсов и расчётных инструментов?

• **Данные:** достаточно ли открытой выборки MERA или нужен независимый набор и проверка агрономом?

• **Методика:** приемлемо ли сравнение разных конфигураций; что исправить в оценке ответов и расчётов?

• **Следующий шаг:** какие доработки приоритетны и под какой учебный или публикационный формат готовить текст?

Если спросят подробнее: короткие ответы

«Получилось 94 % точности?» Нет: точность 9B - 48,79 %. 94 % - отношение 141 к 150. Равенство качества не доказано.

«Можно уже рекомендовать полив?» Полевых испытаний не было. Верное число по формуле не подтверждает безопасность совета. Нужна независимая проверка; открытые задания уже использовались при выборе моделей.

«А облако?» В прежнем отдельном опыте на 150 заданиях каскад сократил обращения к облаку со 100 до 20, но дал 133 верных ответа против 139 у режима «инструменты + облако». Критерий сохранения качества не выполнен.

«Почему так быстро?» ИИ помогал с кодом, анализом и текстом; это раскрыто в статье. Авторы должны проверить итоговый текст.

Основа: RU (r2) и EN от 05.10.2026, сохранённые результаты. Проект и статьи на GitHub • Описание набора